


1η Εργαστηριακή Άσκηση

Οπτική Αναγνώριση Ψηφίων

Μάθημα : Αναγνώριση Προτύπων



Ροή Σ

Συνεργάτες :

- Βαβουλιώτης Γεώργιος (Α.Μ. : 03112083)
- Σταυρακάκης Δημήτριος (Α.Μ. : 03112017)

Σκοπός: Όπως αναφέραμε και στην προπαρασκευή της άσκησης αυτής, σκοπός μας είναι να υλοποιήσουμε ένα σύστημα οπτικής αναγνώρισης ψηφίων. Η συνέχεια λοιπόν της προπαρασκευής, περιλαμβάνει την υλοποίηση και σύγκριση αρκετών διαφορετικών ταξινομητών καθώς και τον σχολιασμό των αποτελεσμάτων του καθενός ξεχωριστά αλλά και τελικά συμπεράσματα ώστε να γίνει προφανές ποιός ταξινομητής είναι καλύτερος για το πρόβλημα της οπτικής αναγνώρισης ψηφίων.

Εκτέλεση Άσκησης

Βήμα 10 : Στο βήμα αυτό καλούμαστε να υπολογίσουμε τις a-priori πιθανότητες των ψηφίων. Είναι προφανές ότι για τον υπολογισμό των a-priori θα χρησιμοποιήσουμε τα train δεδομένα. Συγκεκριμένα η a-priori πιθανότητα για κάθε ψηφίο προκύπτει από το λόγο του πλήθους εμφάνισης κάθε ψηφίου προς το μέγεθος των train data, δηλαδή :

$$Pr[C_k] = \frac{\text{πλήθος εμφανίσεων digit } k}{\text{πλήθος train data}}$$

Προφανώς τις a-priori πιθανότητες τις κρατάμε σε ένα πίνακα αφού θα μας φανούν χρήσιμες στη συνέχεια.

Βήμα 11 : Στο βήμα αυτό καλούμαστε να υλοποιήσουμε ένα Bayesian ταξινομητή για να κάνουμε την ταξινόμηση των test δεδομένων σε μια από τις 10 κατηγορίες. Στη προσπάθεια μας αυτή, θα χρησιμοποιήσουμε τις μέσες τιμές και τις διασπορές που υπολογίσαμε στο ερώτημα 7 της προπαρασκευής. Αρχικά θα πρέπει να πούμε ότι υλοποιήσαμε με τη βοήθεια του Matlab ένα Gaussian Naive Bayesian Classifier (υποθέτουμε δηλαδή ότι τα digits ακολουθούν κανονική κατανομή με μέση τιμή και διασπορά αυτές του βήματος 7), ο οποίος θα κατατάσσει κάθε ψηφίο στη παρακάτω κατηγορία, μεγιστοποιώντας στην ουσία την posterior πιθανότητα :

$$y = \underset{k}{\operatorname{argmax}} Pr[C_k] \cdot Pr[x | C_k]$$

Επειδή έχουμε ανεξαρτησία χαρακτηριστικών μπορούμε να χρησιμοποιήσουμε τον λογάριθμο της έκφρασης μέσα στο argmax όπως είχαμε αναφέρει και στις διαλεξεις του μαθήματος και προκύπτει :

$$y = \underset{k}{\operatorname{argmax}} \log(Pr[C_k] \cdot Pr[x | C_k]) = \underset{k}{\operatorname{argmax}} \log\left(\prod_{i=1}^N (Pr[C_{k_i}] \cdot Pr[x | C_{k_i}])\right) = \underset{k}{\operatorname{argmax}} \left(\sum_{i=1}^N \log(Pr[x | C_{k_i}]) + \log(Pr[C_{k_i}])\right)$$

όπου $Pr[x | C_{k_i}] = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ και $N=256$.

Επομένως αυτή είναι η ιδέα με την οποία υλοποιήσαμε τον Bayesian ταξινομητή μας. Το success ratio που μας έδωσε όπως αυτό φαίνεται στο Matlab είναι το εξής :

Naive Bayesian Success Ratio : 70.5531

Για πληρότητα σας παρουσιάζουμε και το success ratio για καθένα απο τα digits που κατάφερε ο ταξινομητής αυτός :

Naive Bayesian Success Ratio of 0
80.7799

Naive Bayesian Success Ratio of 1
96.5909

Naive Bayesian Success Ratio of 2
61.1111

Naive Bayesian Success Ratio of 3
50

Naive Bayesian Success Ratio of 4
27.5000

Naive Bayesian Success Ratio of 5
40

Naive Bayesian Success Ratio of 6
91.7647

Naive Bayesian Success Ratio of 7
87.0748

Naive Bayesian Success Ratio of 8
66.2651

Naive Bayesian Success Ratio of 9
87.0056

Βήμα 12 : Το βήμα αυτό είναι ίδιο με το βήμα 11 μόνο που πλέον καλούμαστε να υλοποιήσουμε ένα Bayesian ταξινομητή υποθέτοντας ότι η διασπορά πλέον είναι 1 για όλα τα χαρακτηριστικά. Η συλλογιστική πορεία που ακολουθήσαμε είναι ακριβώς η ίδια με το βήμα 11 και το αποτέλεσμα το οποίο πήραμε όσο αφορά το success ratio αυτού του Bayesian ταξινομητή φαίνεται παρακάτω :

Naive Bayesian (with Variance equal to 1) Success Ratio : 81.2656

Για πληρότητα σας παρουσιάζουμε και το success ratio για καθένα από τα digits που κατάφερε ο ταξινομητής αυτός :

Naive Bayesian (with Variance equal to 1) Success Ratio of 0
82.7298

Naive Bayesian (with Variance equal to 1) Success Ratio of 1
98.1061

Naive Bayesian (with Variance equal to 1) Success Ratio of 2
73.2323

Naive Bayesian (with Variance equal to 1) Success Ratio of 3
78.9157

Naive Bayesian (with Variance equal to 1) Success Ratio of 4
75

Naive Bayesian (with Variance equal to 1) Success Ratio of 5
76.2500

Naive Bayesian (with Variance equal to 1) Success Ratio of 6
84.1176

Naive Bayesian (with Variance equal to 1) Success Ratio of 7
79.5918

Naive Bayesian (with Variance equal to 1) Success Ratio of 8

Naive Bayesian (with Variance equal to 1) Success Ratio of 9
79.0960

Σχολιασμός αποτελεσμάτων Βημάτων 11 και 12 : Παρατηρούμε ότι ο δεύτερος Bayesian Classifier έχει μεγαλύτερο success ratio, με άλλα λόγια βλέπουμε ότι δίνει καλύτερα αποτελέσματα εκείνος ο ταξινομητής ο οποίος δεν λαμβάνει υπόψη την πραγματική διασπορά αλλά εκείνος που την θεωρεί παντού ίση με 1. Αυτό γίνεται ο ταξινομητής του βήματος 12 έχει μεγάλη απόκλιση από τις μέσες τιμές άρα κάνουμε καλή πρόβλεψη επειδή έχουμε κανονική κατανομή και όπως είναι γνωστό το 95% των δειγμάτων βρίσκονται στο διάστημα $(m-v, m+v)$. Θα πρέπει να επισημάνουμε ότι στο Βήμα 11 στη διασπορά προσθέσαμε ένα μικρό παράγοντα ώστε να μην υπάρχουν διασπορές χαρακτηριστικών ίσες με το 0 για να πάρουμε ένα καλύτερο αποτέλεσμα. Εν κατακλείδι αυτό που καταλαβαίνουμε είναι ότι δεν είναι πάντα καλό να λαμβάνουμε υπόψη μας τις πραγματικές τιμές της διασποράς για να κάνουμε καλό classification.

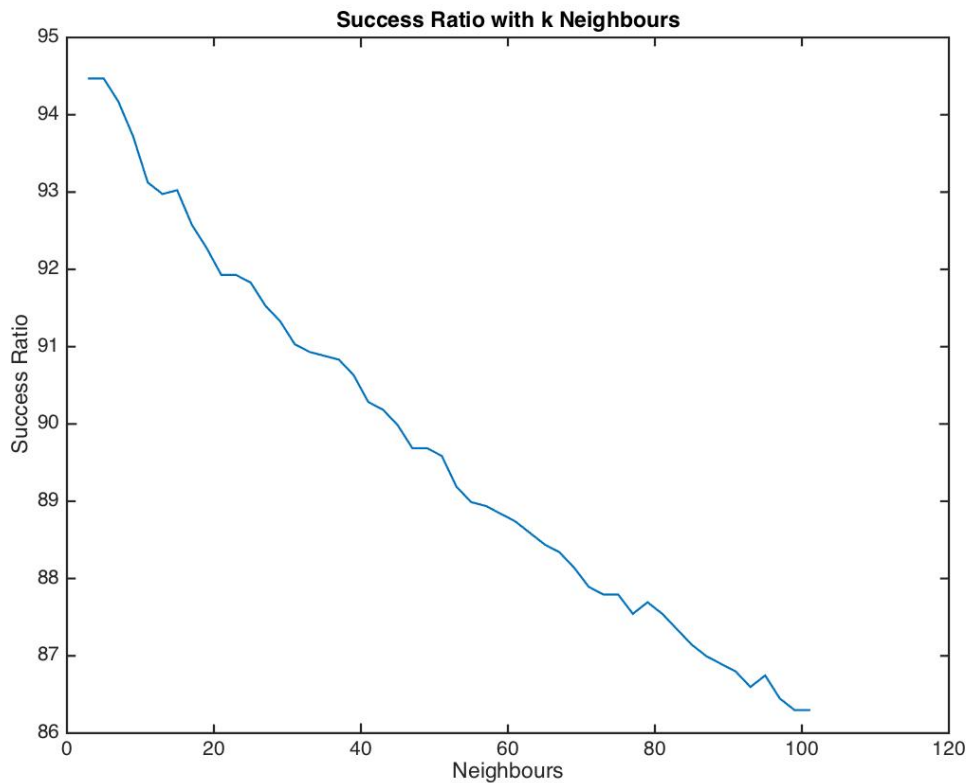
Βήμα 13 : Στο βήμα αυτό καλούμαστε να υλοποιήσουμε τον αλγόριθμο του κοντινότερου γείτονα-1(NNR-1), για να κάνουμε classification για τα 100 digits των test δεδομένων. Η ιδέα που υλοποιούμε στο Matlab είναι ότι για καθένα από τα 100 ψηφία των test data υπολογίζουμε τις αποστάσεις από τα train δεδομένα. Βρίσκοντας την ελάχιστη απόσταση από αυτές για κάθε digit καταφέρνουμε να κατατάξουμε το κάθε digit των test δεδομένων στην κατηγορία που ανήκει το ψηφίο των train data από το απέχει λιγότερο. Το success ratio που πήραμε με χρήση του NNR-1 χρησιμοποιώντας 100 test data και 1000 train είναι το παρακάτω :

NNR1 Ratio:
90

Βήμα 14 : Στο Βήματα 14(α),14(β) αυτό που έχουμε να κάνουμε είναι να ταξινομήσουμε όλα τα test δεδομένα με χρήση όλων των train δεδομένων με την βοήθεια του αλγορίθμου NNR-1. Η συλλογιστική που ακολουθήσαμε είναι η ίδια, με την εξαίρεση ότι πλέον έχουμε να κάνουμε με περισσότερα δεδομένα test και train. Το success ratio που πήραμε με χρήση του NNR-1 χρησιμοποιώντας όλα τα test και train data είναι το παρακάτω :

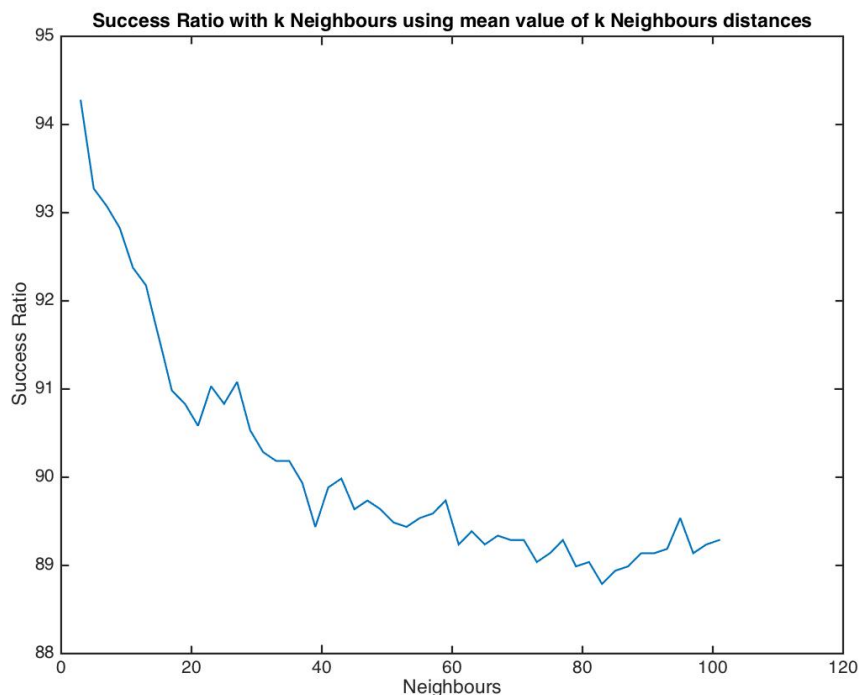
NNR1 Ratio of Total Classification:
94.3697

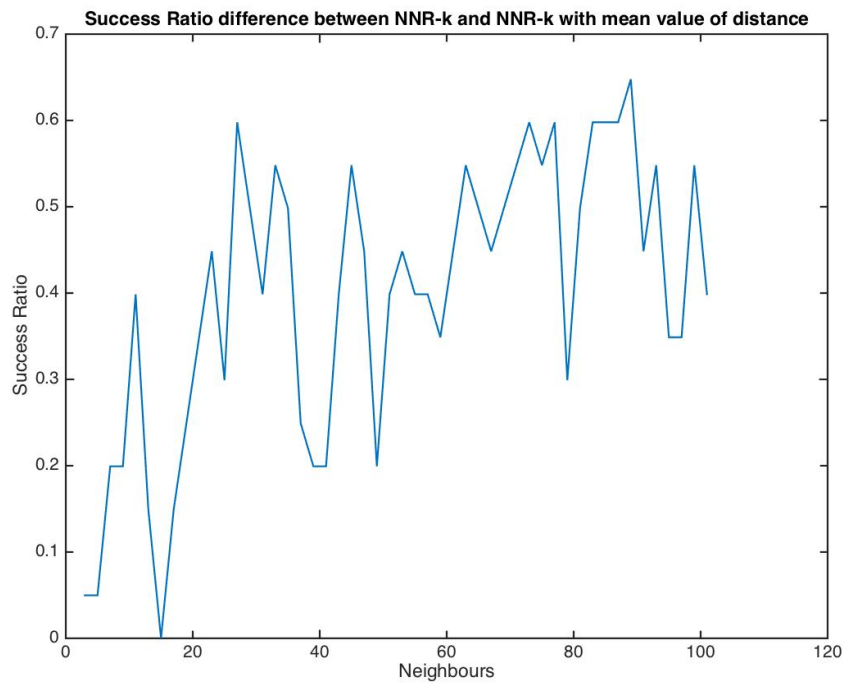
Στο βήμα 14(γ) χρησιμοποιούμε τον αλγόριθμο NNR-k δηλαδή για κάθε test δεδομένο βρίσκουμε τους k κοντινότερους γείτονες του από τα train δεδομένα και το κατατάσσουμε στην κατηγορία εκείνη στην οποία ανήκουν οι περισσότεροι από τους k γείτονες του. Ενδεικτικά βάλαμε το k να πηγαίνει από 3 με βήμα 2(αφού θέλουμε περιττές τιμές του k) μέχρι την τιμή 101 και δημιουργήσαμε το παρακάτω διάγραμμα το οποίο δείχνει το success ratio για τις διάφορες τιμές του k:



Σχολιασμός : Απο το παραπάνω διάγραμμα είναι προφανές οτι όσο αυξάνεται το k τόσο το success ratio μειώνεται.

Στη συνέχεια, στο Βήμα 14(δ) αυτό που καλούμαστε να κάνουμε είναι να βελτιώσουμε τον αλγόριθμο NNR- k . Η ιδέα που υλοποιήσαμε στο σημείο αυτό είναι η εξής: Αντί να επιλεγθεί αυθαίρετα η κλάση στην οποία ανήκουν οι περισσότεροι, επιλέγεται η κλάση στην οποία εμφανίζεται μικρότερη μέση τιμή απόστασης των k γειτόνων από το test δεδομένο. Στη συνέχεια παρατίθενται συγκριτικά διαγράμματα της βελτιωμένης έκδοσης του αλγορίθμου σε σχέση με τον κλασσικό NNR- k αλγόριθμο(το πρώτο δείχνει το success ratio της βελτιωμένης έκδοσης καθώς αυξάνεται το k και το δεύτερο είναι η σύγκριση αυτής με τον κλασσικό αλγόριθμο καθώς αυξάνεται το k) :





Σχολιασμός : Απο το πρώτο διάγραμμα βλέπουμε εκ νέου οτι όταν αυξάνεται το k μειώνεται το success ratio. Απο το δεύτερο διάγραμμα γίνεται αντιληπτό ότι η βελτίωση των μέσων τιμών είναι αισθητά καλύτερη από τον κλασσικό αλγόριθμο όταν ληφθούν υπόψην αρκετοί γείτονες.όπου φαίνεται και πάλι ότι αύξηση του k μειώνει το ποσοστό επιτυχίας.

Βήμα 15 : Στο βήμα αυτό καλούμαστε να υλοποιήσουμε 2 ακόμα ταξινομητές στους οποίους θα πρέπει να συμπεριλάβουμε τα SVM, τα οποία είναι είναι μοντέλα τα οποία εκτός των άλλων χρήσεων τους μπορούν να χρησιμοποιηθούν και ως πιθανοτικοί ταξινομητές. Η ιδέα πάνω στην οποία στηρίζονται τα SVMs είναι ότι τοποθετούν ένα δεδομένο σε μια από τις δυο κατηγορίες που τους δίνονται μεγιστοποιώντας την απόσταση από την επιφάνεια απόφασης. Αυτό που εμείς υλοποιήσαμε με τη βοήθεια του Matlab είναι 10 SVM ταξινομητές, ένας για κάθε digit, όπου ο καθένας εξετάζει αν ένα ψηφίο ανήκει στην κατηγορία για την οποία εκείνος είναι υπεύθυνος. Όπως αναφέρεται και στην εκφώνηση της άσκησης χρησιμοποιήσαμε δυο είδη πυρήνων, ένας γραμμικός και ένας πολυωνμικός άρα συνολικά 20 SVM ταξινομητές.

Όπως είναι όμως προφανές υπάρχει και η περίπτωση κάποιο ψηφίο να κατατάσσεται από 2 ή περισσότερους ταξινομητές στην κλάση τους. Στο σημείο αυτό εμείς θα πρέπει να είμαστε σε θέση να αποφασίσουμε σε ποιά κλάση τελικά θα ταξινομηθεί ο ψηφίο αυτό. Ο διαχωρισμός έγινε με χρήση ενός score για κάθε κλάση και τελικά επιλογή της κλάσης με το μικρότερο score. Η εκπαίδευση των ταξινομητών έγινε με χρήση της συνάρτησης svmtrain() του matlab, στην οποία δώσαμε σαν ορίσματα τα train data, πίνακα για την κατάταξη των κλάσεων, το είδος του πυρήνα και για options = max_iter όπως θεωρήσαμε κατάλληλο βάση των doc του mathworks. Μετά την εκπαίδευση, χρησιμοποιούμε την συνάρτηση mysvmclassify(τροποποιημένη εκδοχή της Built-in svmclassify του matlab) ώστε αυτή να μας επιστρέφει και το score που χρειαζόμαστε για την κατηγοριοποίηση των ψηφίων. Η πηγή από την οποία βοηθηθήκαμε υπάρχει στη function mysvmclassify. Αφού λοιπόν τα κάναμε όλα αυτά υπολογίσαμε τα κατάλληλα ratios που μας δίνουν αυτοί οι ταξινομητές.

Το success ratio για τον γραμμικό SVM ταξινομητή είναι το εξής :

Svm with Linear Kernel Success Ratio : 89.9352

Το success ratio για τον πολυωνμικό SVM ταξινομητή είναι το εξής :


Svm with Polynomial Kernel Success Ratio : 90.0847

Ο έταιρος ταξινομητής που χρησιμοποιήσαμε είναι ο Fit discriminant analysis classifier. Αυτό επιτεύχθηκε με τη βοήθεια της fitcdiscr() του Matlab σε συνδυασμό με την predict() (η αντίστοιχη αναφορά στο mathworks υπάρχει επίσης στο script). Υπολογίσαμε και τα success ratio αυτού του ταξινομητή. Το success ratio για τον Fit discriminant analysis classifier είναι το εξής :

Fit discriminant analysis classifier Success Ratio : 88.5401

Τα success ratio per digit για καθένα απο τους παραπάνω ταξινομητές(svm liner, svm polynimial, fit discriminant) υπάρχουν στο zip αρχείο που σας παραδίδω σε mat files με όνοματα αντίστοιχα των ταξινομητών παραπάνω, για να μην τα βάλω και αυτά με screenshot και γίνει πολύ μεγάλη η αναφορά.

Βήμα 16 : Στο πρώτο ερώτημα του βήματος αυτού καλούμαστε να συνδυάσουμε διάφορους απο τους ταξινομητές τους οποίους έχουμε υλοποιήσει ώστε να καταφέρουμε να πετύχουμε καλύτερο αποτέλεσμα. Στη συνέχεια σας παρουσιάζω ενα διάγραμμα το οποίο δείχνει το total success ratio κάθενα απο τους ταξινομητές που θα χρησιμοποιήσουμε για να φτιάξουμε ενα συνδυασμό απο ταξινομητές :



Η λογική με την οποία θα συνδυάσουμε τους ταξινομητές είναι οτι εμπιστευόμαστε κάθε φορά την πλειοψηφία των κατηγοριοποιήσεων για να καταφέρουμε να πάρουμε καλύτερο αποτέλεσμα απο τα επιμέρους. Θα πρέπει να τονιστεί οτι σε περίπτωση απουσίας πλειοψηφίας εμπιστευόμαστε τα αποτελέσματα εκείνων των ταξινομητών με το μεγαλύτερο success ratio(αυτό το κάναμε για να είμαστε πλήρως σωστοί, ωστόσο βρήκαμε οτι οι ισοπαλίες είναι 10 το πλήθος κάτι το οποίο σημαίνει οτι ο μη χειρισμός τους δεν θα χαλούσε κατά πολύ το αποτέλεσμα). Τέλος ο combo classifier που φτιάξαμε πετυχαίνει success ratio ίσο με :

Combining classifiers Success Ratio : 91.6293

Παρατηρούμε ότι δεν είναι και το καλύτερο δυνατό αποτέλεσμα αφού με μια γρήγορη ματιά βλέπουμε ότι ο NNR-1 δίνει οριακά καλύτερα αποτελέσματα από μόνος του. Το αποτέλεσμα αυτό είναι λογικό αν σκεφτεί κανείς ότι κάναμε συνδυασμό ταξινομητών που ενδεχομένως έχουν κοινά λάθη. Το success ratio per digit για τον combo classifier υπάρχει στο zip αρχείο που σας παραδίδω σε mat file με όνομα αντίστοιχ του ταξινομητή παραπάνω, για να μην τα βάλω και αυτά με screenshot και γίνει πολύ μεγάλη η αναφορά.

Για να καταφέρουμε καλύτερο αποτέλεσμα του combo classifier μπορούμε πλέον να χρησιμοποιήσουμε κάποιους από τους NNR-k ταξινομητές, Συγκεκριμένα αν επιλέξουμε εκείνους με $k = 3$ και $k = 9$ (ώστε και πάλι να έχω περιτό αριθμό ταξινομητών), το αποτέλεσμα που πήραμε όσο αφορά το success ratio για τον νέο combo classifier είναι 94,38% το οποίο προφανώς καλύτερο από το προηγούμενο. Γενικά μπορούμε να πετύχουμε και πολύ καλύτερα αποτελέσματα αν κάνουμε καλύτερο συνδυασμό.